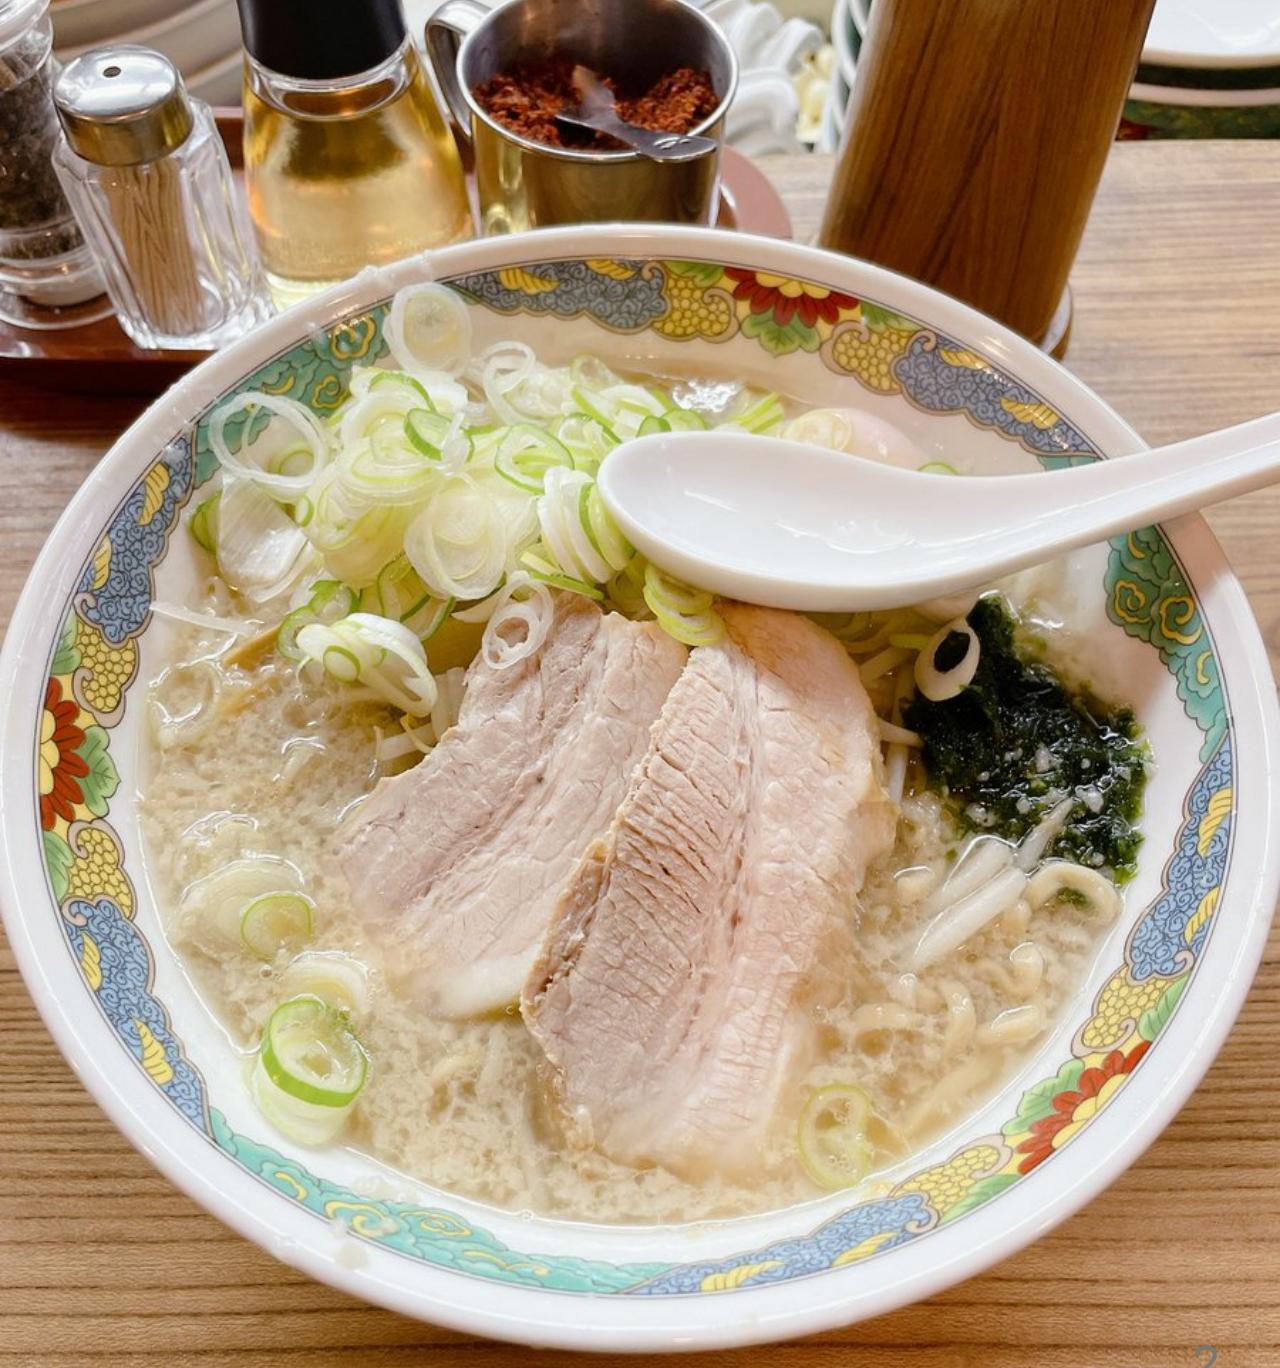


バイアスのあるデータをIPWで補正してUplift Modeingを
やってみた

自己紹介

- 小沼 墨, [@knmr_u](#)
- 職業とか趣味とか
 - 機械学習エンジニア
 - PMに鞍替え中
 - kaggle, 銅 1 (だけ)



話す内容

テーマ

- バイアスのあるデータを IPW で補正して Uplift Modeling をやってみたよ

TL;DR

- Uplift Moddeling で介入効果を最大化できるよ
- バイアスのあるデータでも Uplift Modeling ができたよ
- ただし、傾向スコアをあまり信じすぎるのは危ないよ

参考資料

- 仕事で始める機械学習
- 岩波データサイエンス vol.03



実装について

- 自作ライブラリ [pycalf](#) を作りました
- 今回の実装については上記のライブラリにまとまっています

ToC

1. Uplift Modeling による介入効果の最大化
2. Uplift Modeling の弱点
3. IPW (Inverse Probability Weighting) とは
4. IPW で Uplift Modeling の弱点を補填
5. バイアスを補填した Uplift Modeling の結果
6. IPW (傾向スコア) の弱点
7. おまけ

Uplift Modeling による介入効果の最大化

Uplift Modeling の目的

- 何らかのマーケティング施策を想定する
- 右図のような四象限を仮定する
- Uplift Modeling では、介入することでCVする群である「説得可能」を見つける

	CVする	CVしない
介入あり	説得可能	天邪鬼
介入なし	鉄板	無関心

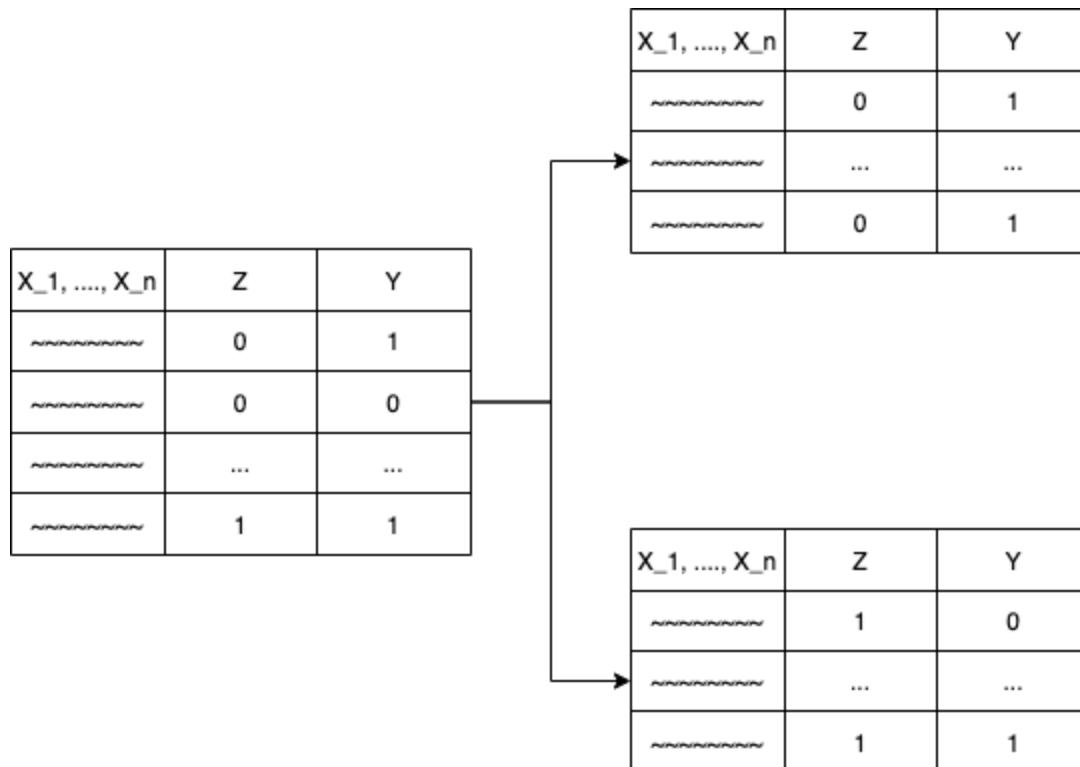
ABテストを通じたUplift Modelingの手順(1/7)

- ABテストを行い、以下のデータを取得する
 - X: 特徴量, Z: 介入有無 (0 or 1), Y: CV有無 (0 or 1)

X_1, ..., X_n	Z	Y
~~~~~	0	1
~~~~~	0	0
~~~~~	...	...
~~~~~	1	1

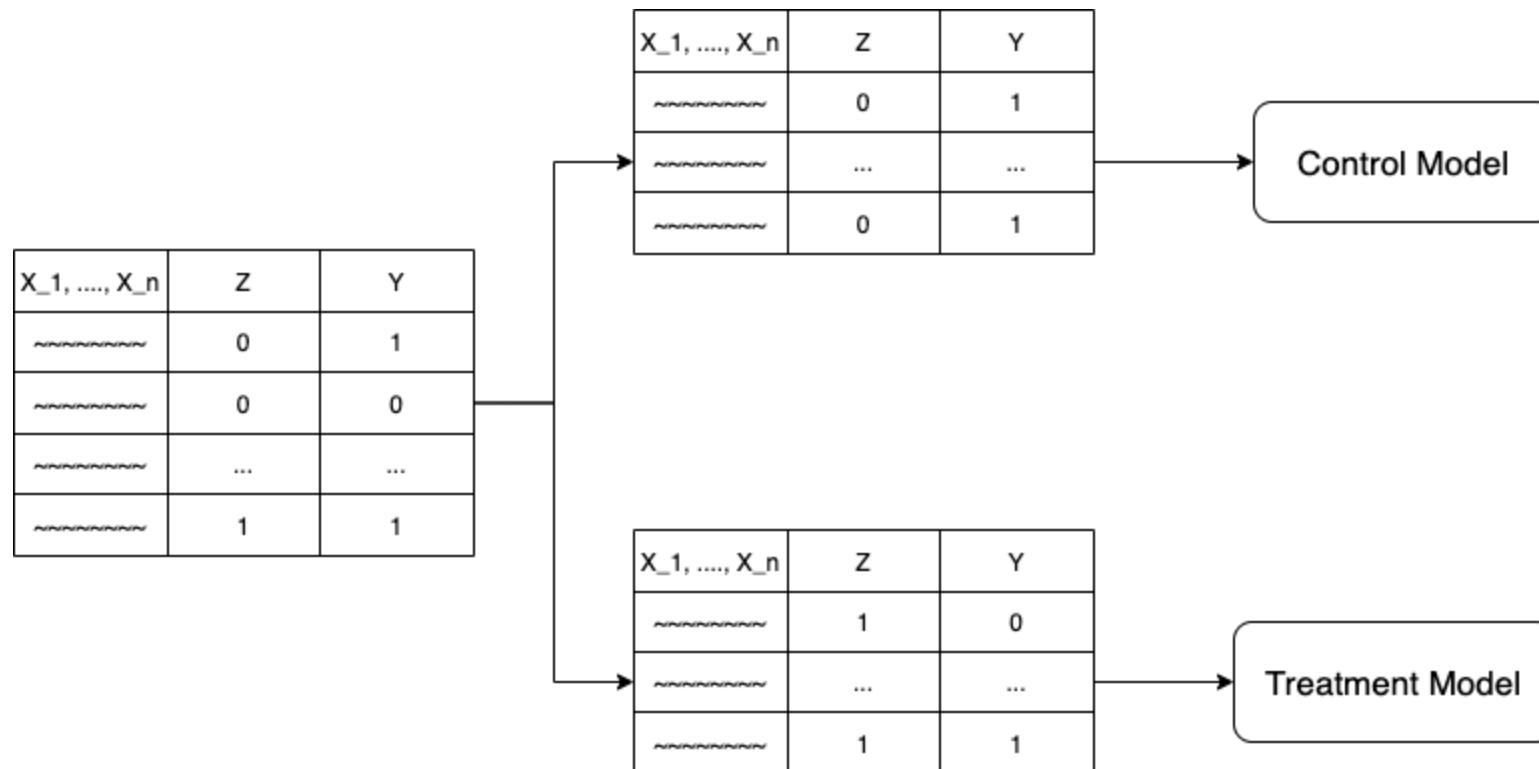
ABテストを通じたUplift Modelingの手順(2/7)

- $Z==0, Z==1$ でデータを分ける
- つまり介入有無でデータを分割する



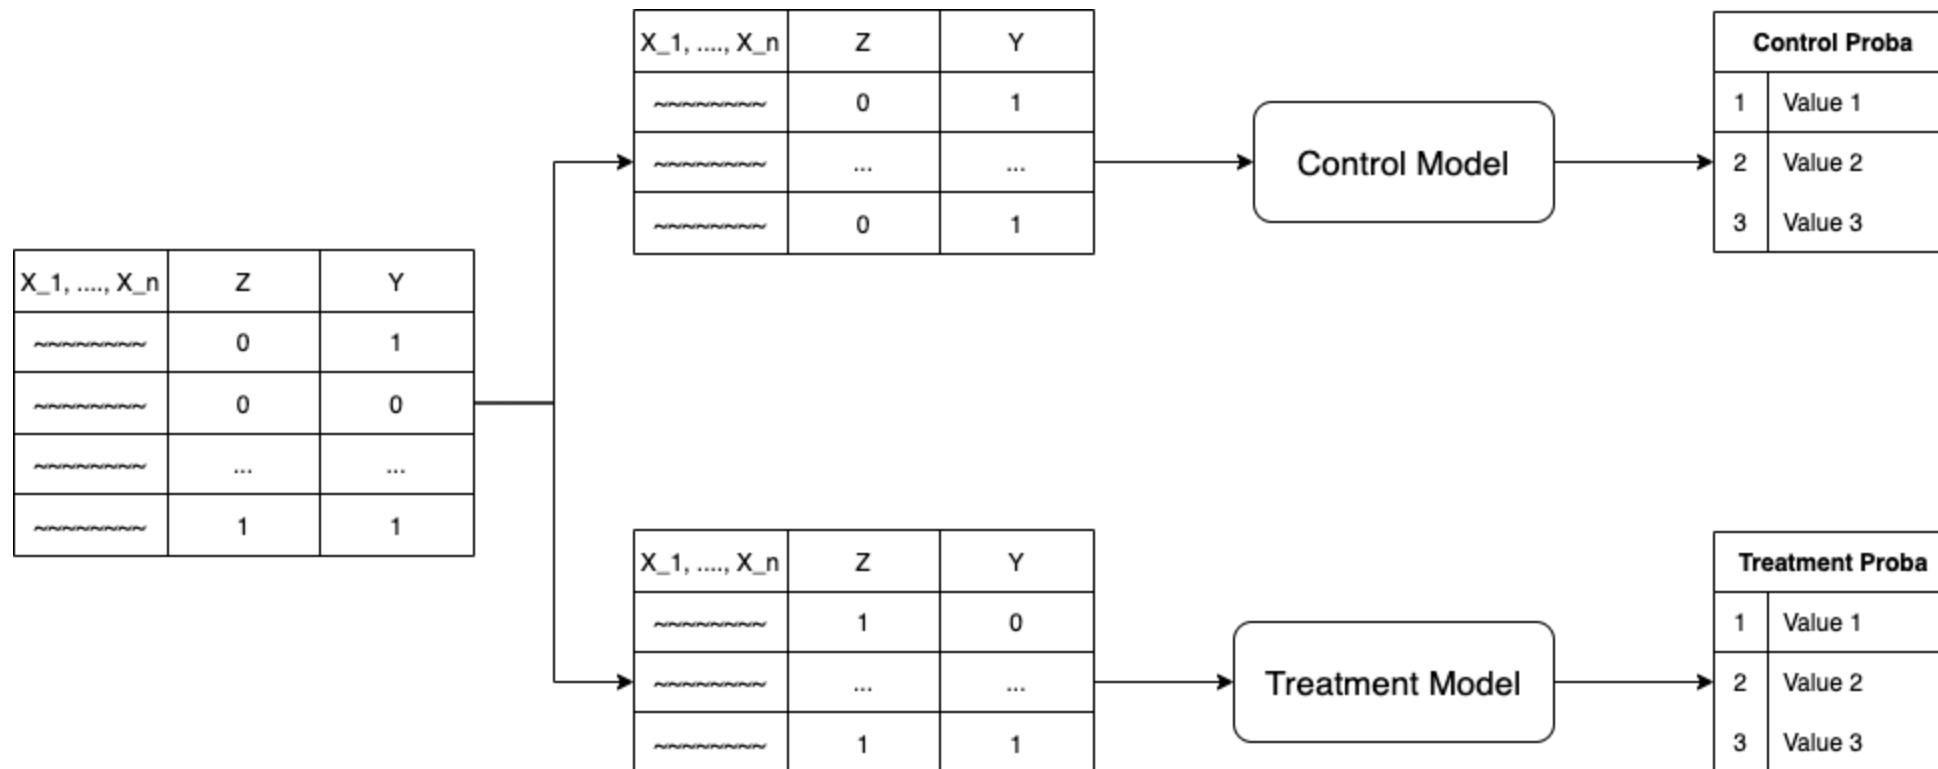
ABテストを通じたUplift Modelingの手順(3/7)

- $Z==0, Z==1$ ごとのモデルを作成



ABテストを通じたUplift Modelingの手順(4/7)

- 同様の検証データに対して作成したモデルで予測

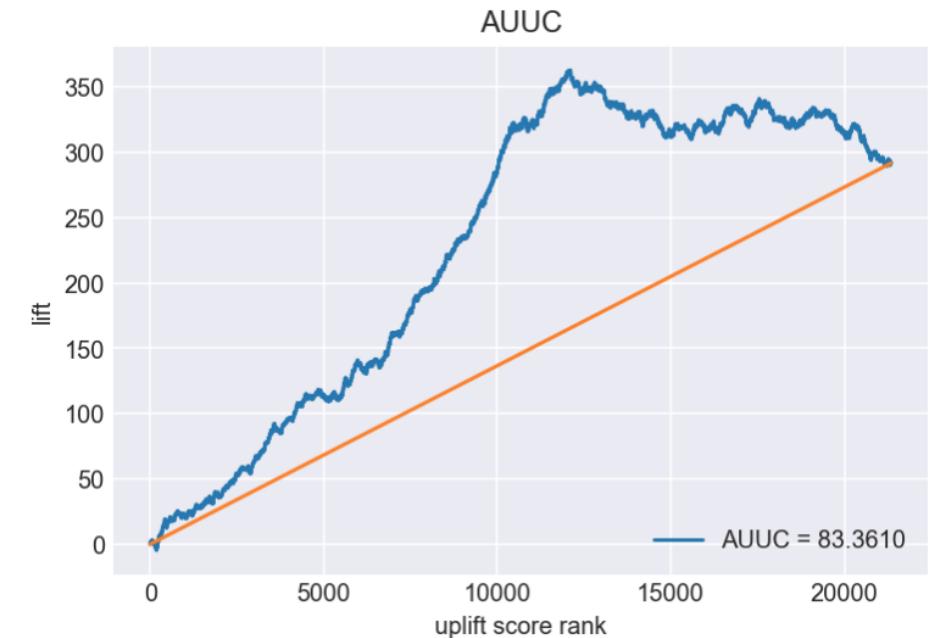


ABテストを通じたUplift Modelingの手順(5/7)

- 予測値からUplift Score と Lift を取得
 - $Uplift_Score = treat_proba / control_proba$
 - $Lift = treat_proba - control_proba$

ABテストを通じたUplift Modelingの手順(6/7)

- AUUC でモデルの評価を行う
- 青い線が介入した場合
- 左からUpliftScoreが高い順に介入効果を積み上げている
- 曲線が下ぶれてくるあたりから天邪鬼が含まれてくる



ABテストを通じたUplift Modelingの手順(7/7)

- UpliftScoreでソートしたLiftの累積和が最大値になるポイントを介入閾値に決定
- AUUCの横軸をデータ数からUpliftScoreに変える
- $\text{UpliftScore} = 1.1$ あたりが最も介入効果が高いことがわかる

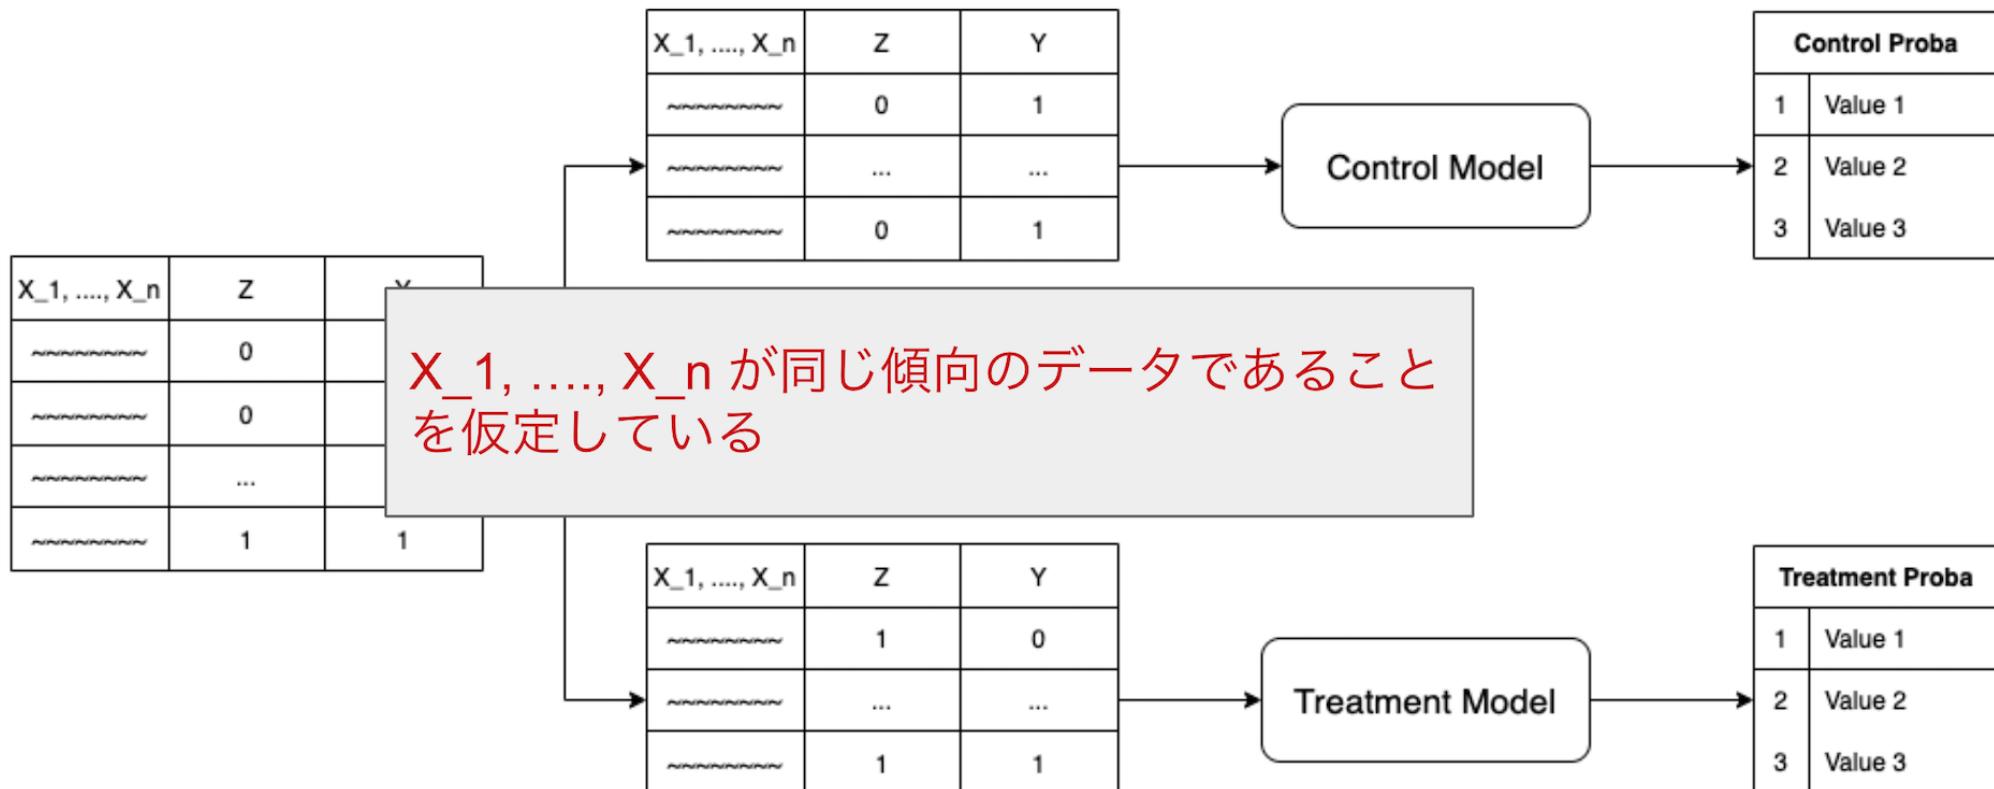


Uplift Modeling の弱点

- ABテストを行ったデータが必要ということ
- (システム構成が複雑だとか？ユースケースあるの？とかは置いてといて)

Uplift Modeling が仮定していること

- ABテストのより得られた反実仮想のデータを学習する



バイアスをIPWで補正

- 介入有無により特徴量に偏りが生じる場合、反実仮想のデータが手に入らない
- そこで、IPWを使えばバイアスを補填できるのではないか！と考えた

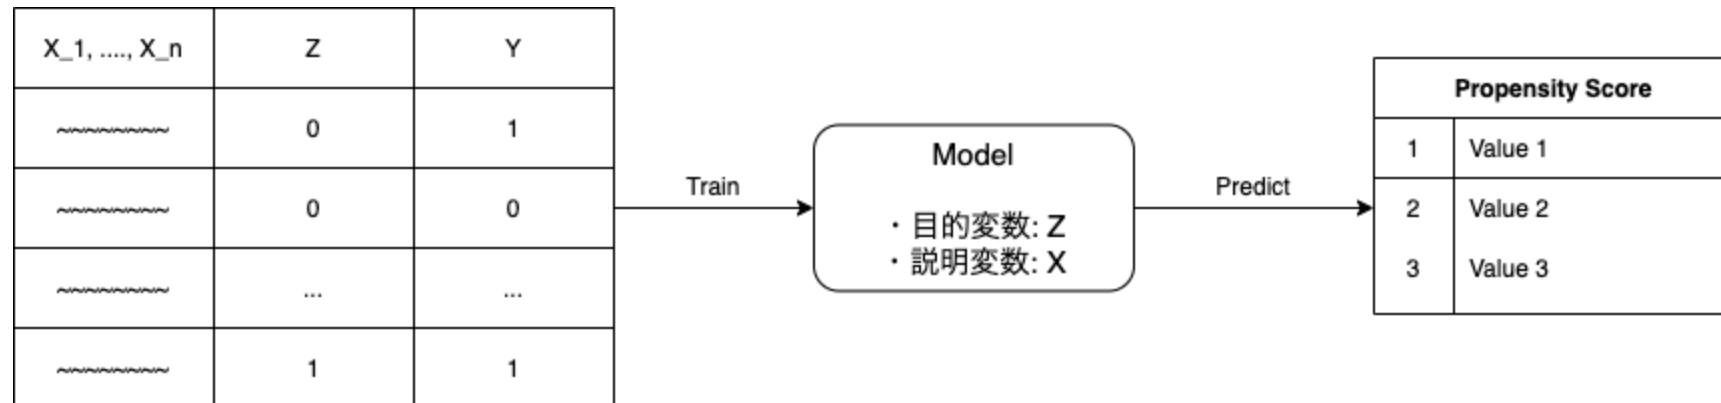
IPW (Inverse Probability Weighting) とは

- 介入有無を学習したモデルの予測値が傾向スコア
- 傾向スコアを逆確率変換したものを重みとする
- これをIPWと呼ぶ
- IPWは介入が必然である個体を軽く、介入が偶然である個体を重く扱う
- 上記のような処理をすることでデータの偏りを調整する

傾向スコアの求め方

- 特徴量から介入有無を予測するモデルを作成
- そのモデルの予測値を傾向スコアとする

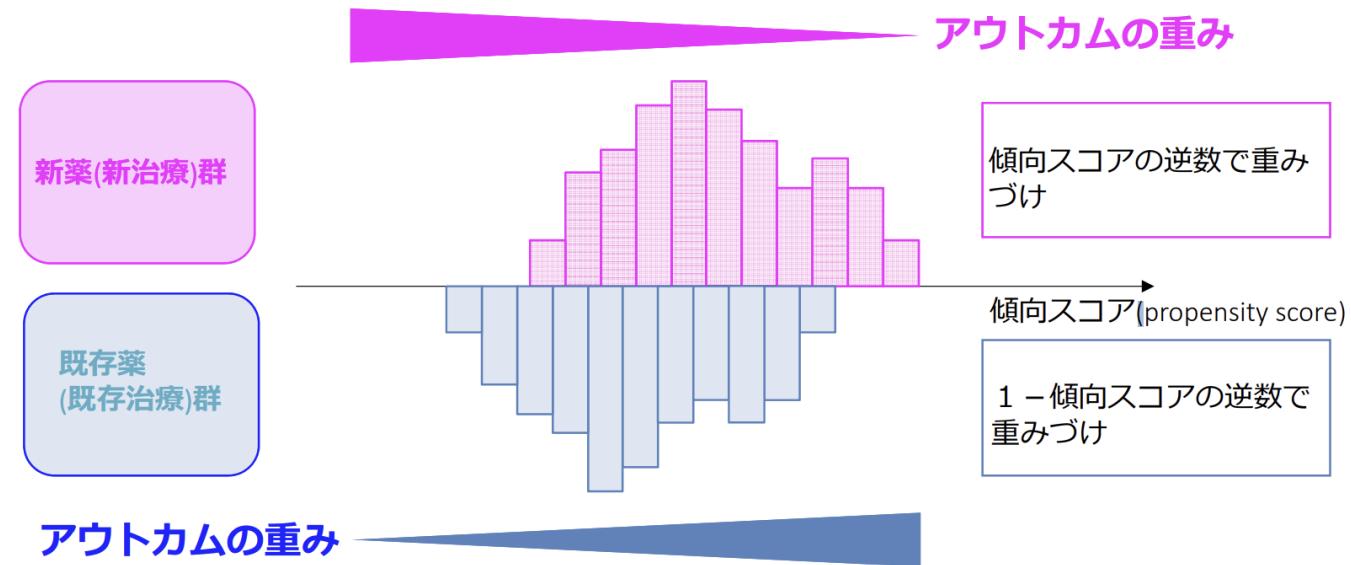
イメージ図



IPWのイメージ図

医学統計アドバンスコース 第4回目

逆数重み付け(IPW: Inverse Probability Weighting)法



逆数重み付け法の場合とは、傾向スコアにおいて新薬・既存薬が選択された必然性が小さい個体の影響を強く、必然性が大きい個体の影響を弱くするように重みを付ける方法である(その極端な状況がマッチングと言える)。

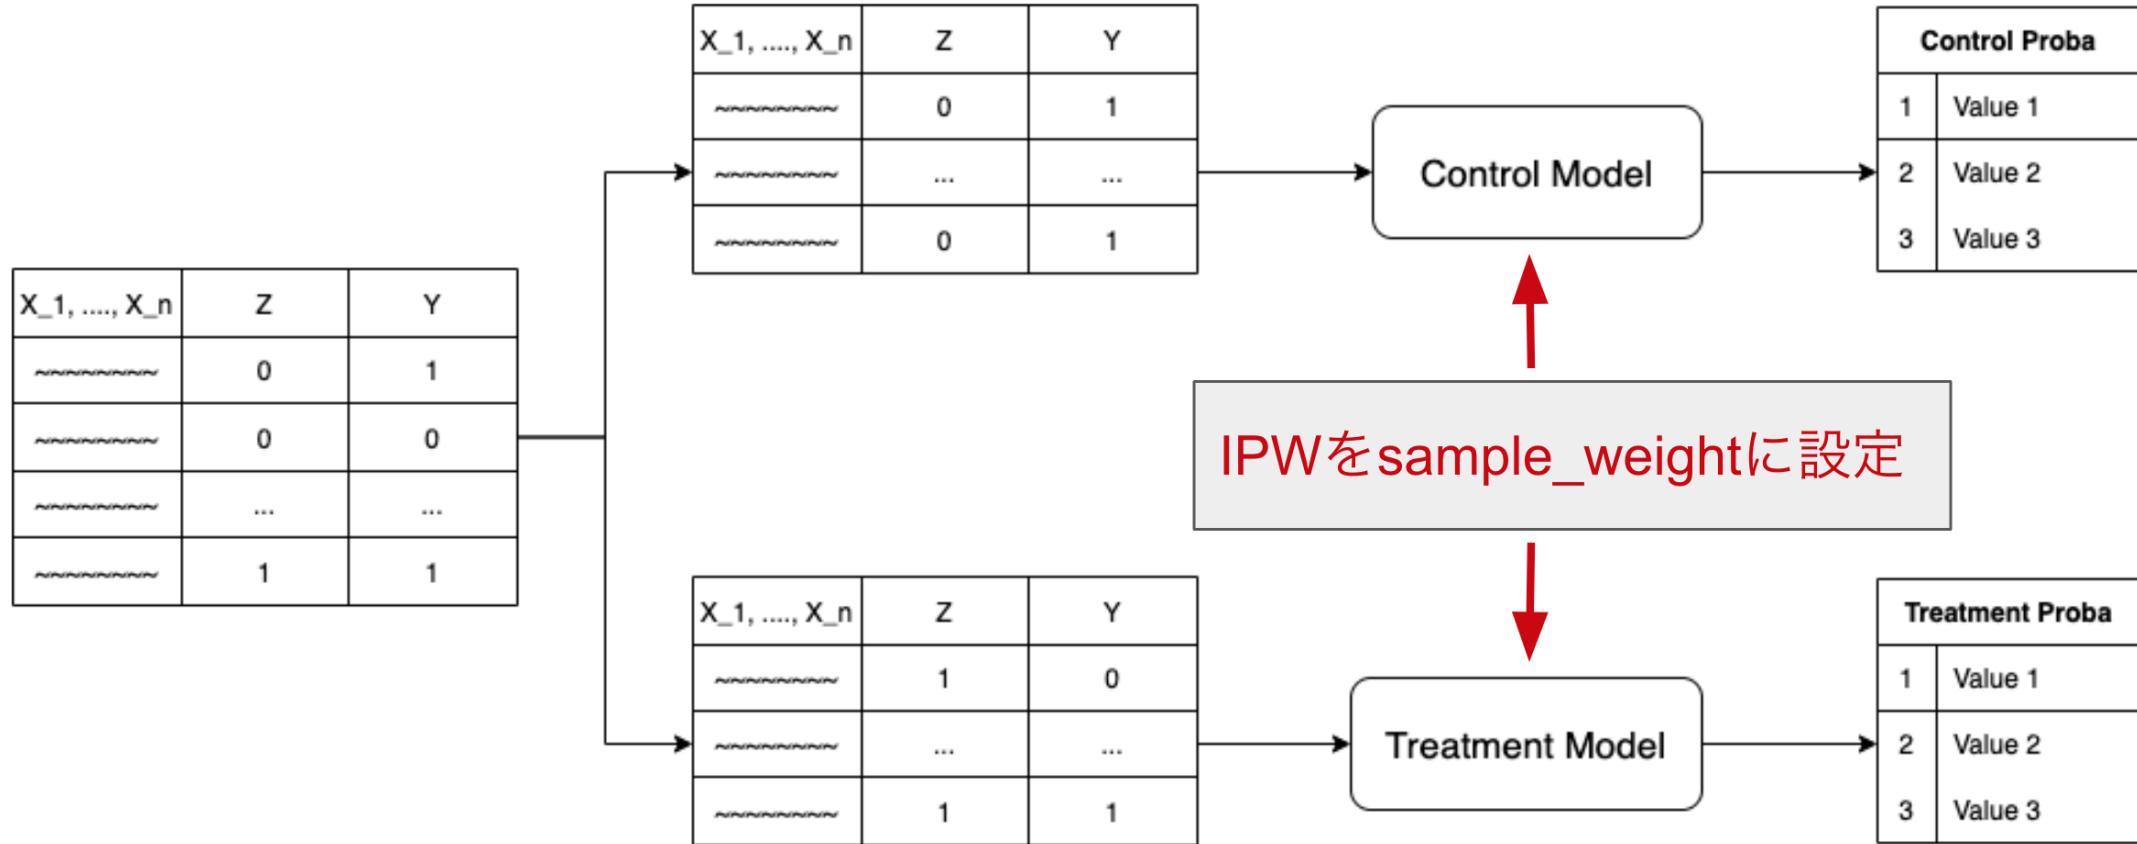
引用: 医学統計セミナー アドバンスコース 統計的因果推論と傾向スコア

IPW で Uplift Modeling の弱点を補填

立ち戻ると、

- バイアスのあるデータで Uplift Modeling がしたい
- しかし、Uplift Modeling はRCTのような反実仮想を想定したデータが必要
- バイアスがあってもIPWによる補正で反実仮想を想定したデータを用意できるのではないか

重み付けモデルのイメージ図

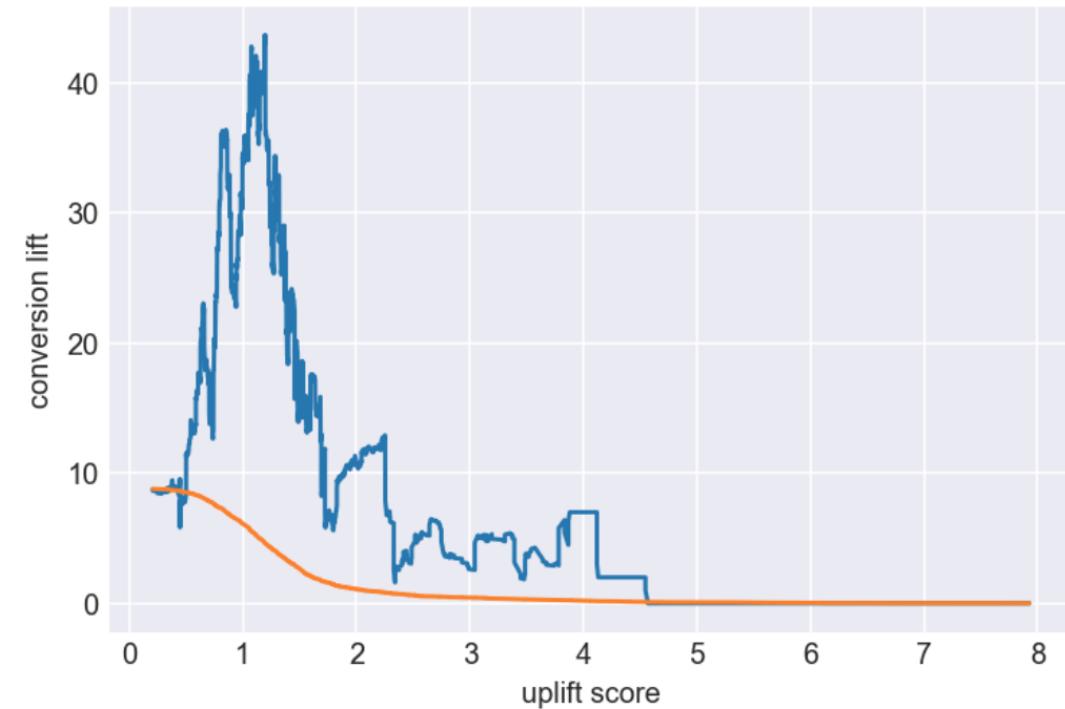
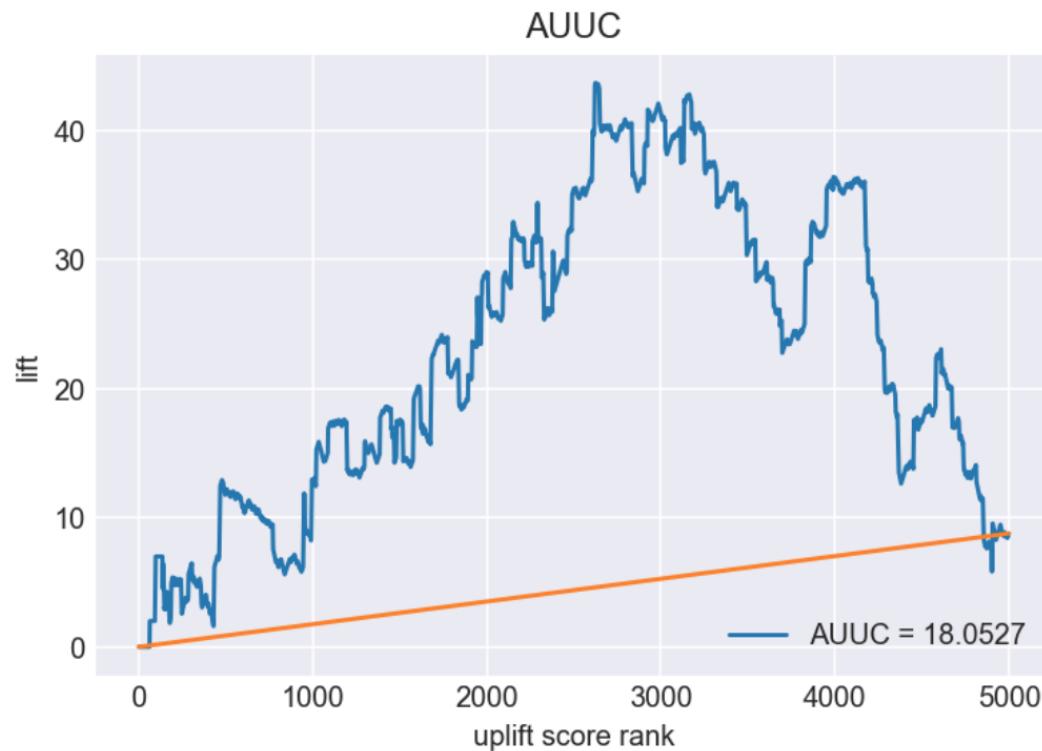


移行の手順は通常のUplift Modelingと同じ

バイアスを補填した Uplift Modeling の結果

それっぽいAUUCが出てくることが確認できた。

曲線のガタツキはデータ量によるものなのでデータが少ないとときは注意が必要



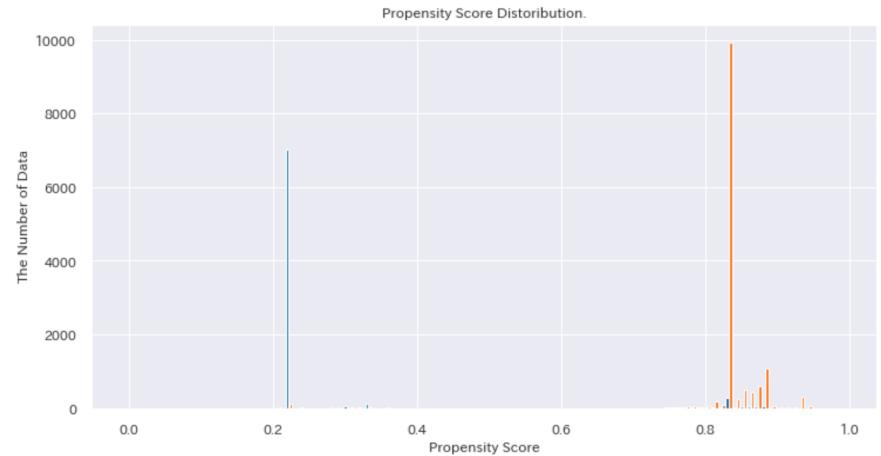
詳しい実装は[こちら](#)

IPWの弱点

分類精度が高すぎる場合、以下のようなことが起こる

- 極端な重み付け
- 同質のデータが存在しない

詳しくは 岩波DS vol.03 で



積み残し

- モデルの検証が不十分
- 意図した振る舞いなのかを検証するのが困難で、
 - ABテストの場合とバイアスがある場合のモデルの比較をしたいが単純には比較できない

検証の方法についてを真面目に考える必要がある

まとめ

- Uplift Modeling で介入効果を最大化できるよ
 - 介入することでCVする「説得可能」なセグメントを見つけることができる
- バイアスのあるデータでも Uplift Modeling ができたよ
 - IPWをsample_weightに設定することで反実仮想を仮定することができる
- ただし、傾向スコアをあまり信じすぎるのは危ないよ
 - 傾向スコアが極端な値を取っていないか、ある程度重なりがあるか確認する必要がある

おまけ

- 実装は [pycalf](#) の example にあります
- 傾向スコアを利用しない手法として Uber が開発していた [causalML](#) がある
 - meta-learner や causal-tree といった手法が使われている（らしい）
 - causalML の調査資料については [これ](#)

おわり